

Gözetimsiz Öğrenme

(İktisatçılar İçin) Makine Öğrenmesi (TEK-ES-2020)

Hüseyin Taştan
Yıldız Teknik Üniversitesi

Plan:


Gözetimli ve gözetimsiz öğrenme

Temel Bileşenler Analizi

K-Ortalamalar Algoritması ile Kümeleme

Hiyerarşik Kümeleme

Gözetimsiz Öğrenme



- Şimdiye kadar sadece gözetimli öğrenme yöntemlerini inceledik. Gözetimli öğrenmede çıktı değişkeni Y ve öznitelik matrisi X birlikte gözlemleniyordu.

- Gözetimsiz öğrenmede ise Y çıktısı ya da etiketi yoktur. Sadece X değişkenleri gözlemlenir.
- Elimizde bir çıktı değişkeni olmadığı için amacımız bu değişkenin kestirimlerini oluşturmak değildir.
- Bunun yerine amaç verilerdeki gizli gruplanmaları ve ilişkileri ortaya çıkarmak ve faydalı bir şekilde görselleştirmektir.

Gözetimsiz Öğrenme

- Gözetimsiz öğrenme yöntemleri keşifsel veri analizinin (exploratory data analysis - EDA) bir parçası olarak da kullanılabilir. Yaygın olarak kullanılan iki gözetimsiz öğrenme yöntemi:
 1. **Temel Bileşenler Analizi (Principal Components Analysis - PCA):** çok boyutlu verilerin görselleştirilmesinde faydalı. Boyut küçültme (dimension reduction) ve gözetimli öğrenme yöntemlerinin öncesinde verileri işlemekten geçirme amacıyla kullanılabilir (örneğin PCA regresyonu).
 2. **Gruplandırma (Clustering):** özellikle büyük veri yığınlarında gizlenmiş homojen grupların ortaya çıkarılması.
 - K-Ortalamalar (K-means) gruplandırma
 - Hiyerarşik gruplandırma (hierarchical clustering)
- Örnek: Bir alışveriş sitesinde müşterilerin kişisel özelliklerine ve alışveriş alışkanlıklarına göre gruplandırılması.
- Ürünlerin kullanıcı yorumları ve değerlendirmelerine göre gruplandırılması
- Hastaların genetik özelliklerine göre gruplandırılması.

Temel Bileşenler Analizi

Temel Bileşenler Analizi

- Temel bileşenler (principal components) nedir?
- Elimizde (X_1, X_2, \dots, X_p) ile gösterdiğimiz p tane öz nitelik olsun. Keşifsel veri analizi amacıyla bu değişkenlerin ikili serpilme grafiklerini (scatter plot) çizmek istediğimizi düşünelim.
- Elimizde kaç tane grafik olur?
- Cevap $= p(p - 1)/2$. Örneğin, $p = 10$ ise 45, $p = 20$ ise 190!
- Daha pratik bir yol: verilerdeki toplam değişkenliğin önemli bir kısmını içeren iki boyutlu bir temsilini bulabilir miyiz?
- PCA: verilerdeki bilginin önemli bir kısmını içeren düşük boyutlu bir temsilini bulmak

Türkiye il verileri 2015 (ilk 10 öznitelik)

Temel Bileşenlerin Bulunması

- **Birinci temel bileşen**, Z_1 , değişkenlerin en yüksek varyansa sahip normalize edilmiş doğrusal bir bileşkesidir:

$$Z_1 = \phi_{11}X_1 + \phi_{21}X_2 + \dots + \phi_{p1}X_p$$

Normalize edilmesinden kasıt ϕ ağırlıklarının (*factor loadings*) kareler toplamının 1 olmasıdır:

$$\sum_{j=1}^p \phi_{j1}^2 = 1,$$

$$\underbrace{\phi_{11}, \phi_{21}, \dots, \phi_{p1}}$$

Birinci bileşenin ağırlıkları


- Birinci temel bileşenin ağırlık vektörü:

$$\phi_1 = (\phi_{11}, \phi_{21}, \dots, \phi_{p1})^T$$

Temel Bileşenlerin Bulunması

Verilerin ortalamadan farkları alındıktan sonra, birinci temel bileşen aşağıdaki optimizasyon probleminin çözümüyle bulunabilir:

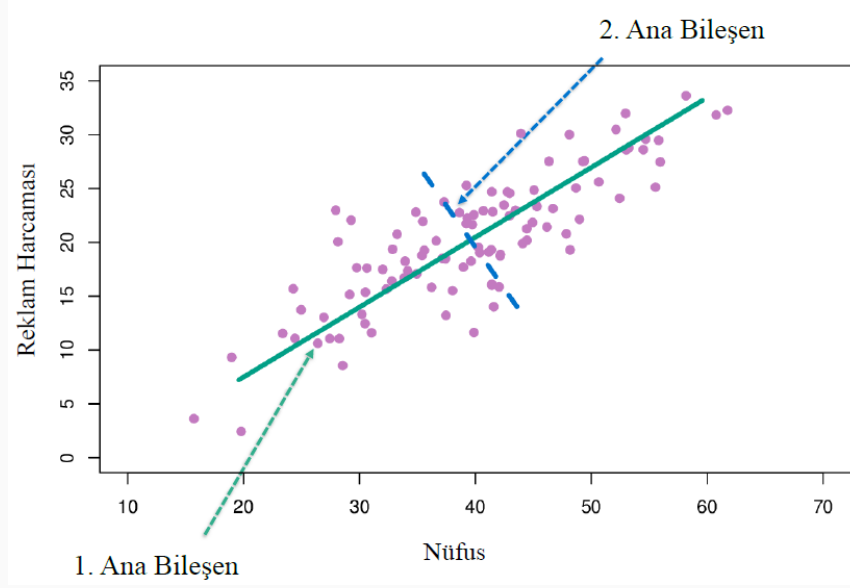
$$\max_{\phi_{11}, \dots, \phi_{p1}} \left\{ \frac{1}{n} \sum_{i=1}^n \left(\sum_{j=1}^p \phi_{j1} x_{ij} \right)^2 \right\} \text{ subject to } \sum_{j=1}^p \phi_{j1}^2 = 1$$



Birinci temel bileşen: verilerin en fazla değişkenlik gösterdiği yön. Bu örnekte $\phi_{11} = 0.839$, $\phi_{21} = 0.544$

$$z_{i1} = 0.839 \text{ Nüfus}_i + 0.544 \text{ Reklam H.}_i$$

Temel Bileşenlerin Bulunması



İkinci temel bileşen: birinci temel bileşenle ilişkisiz en yüksek değişkenliğe sahip doğrusal bileşkedir. Örnekte $\phi_{12} = 0.544$,
 $\phi_{22} = -0.839$

$$z_{i2} = 0.544 \text{ Nüfus}_i - 0.839 \text{ Reklam H.}_i$$

- İkinci temel bileşen birinci temel bileşene ortogonaldır (aralarındaki korelasyon sıfır). Grafikten de görüleceği gibi aralarındaki açı 90 derecedir.

Not: Nüfus ve Reklam Harcamalarının ortalamadan farkları alınmıştır.

Açıklanan varyans oranı

- Temel bileşenler varyansın ne kadarını açıklar?
- Merkezden farkları alınmış bir veri setinde toplam varyans:

$$\sum_{j=1}^p \text{Var}(X_j) = \sum_{j=1}^p \frac{1}{n} \sum_{i=1}^n x_{ij}^2$$


m nci temel bileşen tarafından açıklanan varyans

$$\frac{1}{n} \sum_{i=1}^n z_{im}^2 = \frac{1}{n} \sum_{i=1}^n \left(\sum_{j=1}^p \phi_{jm} x_{ij} \right)^2$$

Açıklanan Varyans Oranı (Proportion of Variance Explained - PVE)

$$PVE_m = \frac{\sum_{i=1}^n \left(\sum_{j=1}^p \phi_{jm} x_{ij} \right)^2}{\sum_{j=1}^p \sum_{i=1}^n x_{ij}^2}$$

Scree (PVE plot)



Açıklanan varyans oranlarının toplamı 1'dir. Bu oranların temel bileşenlere göre grafiğine PVE ya da scree grafiği adı verilir. Bu grafikte ilk iki bileşen değişkenliğin %87'sini açıklamaktadır.


Gruplandırma (Kümeleme)

- Gruplandırmada (clustering) amaç verilerde kendi içinde homojen gözlemleri barındıran alt grupları ortaya çıkarmaktır.
- İyi bir gruplandırmada gözlemler grup içinde birbirine benzer. Gruplar arasında ise çok farklıdır.
- Örnek: Pazar segmentasyonu. Gelir, hane özellikleri, meslek, cinsiyet, vb. değişkenlerden hareketle birbirine benzeyen müşteri gruplarını ortaya çıkarmak.
- Yaygın kullanılan yöntemler
 - K-Ortalama (K-means) gruplandırma
 - Hiyerarşik gruplandırma

K-Ortalamalar

K-Ortalamlar ile Gruplandırma

- Amaç: bir veri setini birbirleriyle örtüşmeyen K gruba ayırmak.



K-Ortalama Gruplandırma

Her bir gruptaki gözlem indekslerini içeren kümeleri C_1, C_2, \dots, C_K ile gösterelim.

Her bir gözlem bir grupta yer alır, yani $C_1 \cup C_2 \cup \dots \cup C_K = \{1, \dots, n\}$

Ayrıca gruplar örtüşmez: $C_k \cap C_{k'} = \emptyset$, her $k \neq k'$ için.

K-ortalamalar gruplandırması: Grup-içi değişkenliği en küçük yapacak şekilde grupları belirler.

Optimizasyon problemi:


$$\min_{C_1, \dots, C_K} \left\{ \sum_{k=1}^K \frac{1}{|C_k|} \sum_{i, i' \in C_k} \sum_{j=1}^p (x_{ij} - x_{i'j})^2 \right\}$$

$|C_k| = k$ grubundaki gözlem sayısı.

k grubundaki tüm gözlem çiftleri arasındaki uzaklığı en küçük yap.

K-Ortalamalar Algoritması

Veriler:




Algoritma adımları:

1. Gözlemleri tesadüfi bir şekilde K gruptan birine ata.
2. İterasyonlar: Yakınsama sağlanıncaya kadar aşağıdaki adımları tekrarla:
 - 2a. Her K grubu için grup merkezini (aritmetik ortalamaları) hesapla.
 - 2b. Gözlemleri en yakındaki geometrik merkezin bulunduğu gruba ata.

K-Ortalamlar Algoritması


Adım 1:

- Gözlemleri rassal olarak K gruba ata.



K-Ortalamalar Algoritması


İterasyon 1, Adım 2a:



- Her bir grup için grup merkezlerini hesapla (grafikte farklı renkte daireler grup merkezleridir)
- Başlangıçta grup ataması tesadüfi yapıldığı için merkezler birbirine çok yakındır.

K-Ortalamalar Algoritması


İterasyon 1, Adım 2b:



- Her bir gözlemi en yakın olduğu merkezin içinde yer aldığı gruba ata.

K-Ortalamalar Algoritması


İterasyon 2, Adım 2a:



- Yeni grup merkezlerini hesapla.
- Grup atamalarını tekrarla (Adım 2b)
- Başa dön, yinele.

K-Ortalamalar Algoritması

Sonuç:



- K-ortalamalar algoritması 10 adımda sonuca ulaştı.
- Ancak bu algoritma sadece lokal optimumu bulmaktadır.
- Ulaşılan sonuç global optimum olmayabilir.
- Bu nedenle farklı başlangıç grup atamalarıyla adımlar tekrarlanarak karşılaştırılabilir.

K-Ortalamalar Algoritması



(ISLR, Fig-10.7, p.390)


- Grafikte farklı başlangıç koşulları ile çalıştırılan 6 K-Ortalamalar çözümü gösterilmektedir.
- Birincisinde minimum değer 320.9, ikincisinde ise 235.8'dir. Bu çözümlerin lokal olduğu unutulmamalıdır.
- Farklı başlangıç değerleriyle algoritma tekrar çalıştırılarak sonuçlar karşılaştırılmalıdır. Buradaki örnekte en iyi çözüm 235.8 amaç fonksiyonu değerini veren çözümdür. (Not: 2-3-4-5 çözümleri renkler farklı olsa da aynıdır.)

Hiyerarşik Kümeleme

Hiyerarşik Gruplandırma


- K-ortalamalar algoritmasında grup sayısının bilinmesi gerekir. Verilerde kaç tane grup olduğunu belirlemek şarttır.
- Ancak K 'yi bilmiyorsa ya da belirlemek istemiyorsa Hiyerarşik Gruplandırmayı tercih edebiliriz.
- Hiyerarşik gruplandırmada K 'nin bilinmesi gerekmez. Ayrıca verilerin nasıl gruplandırıldığını gösteren bir ağaç grafiği (dendrogram) çizilebilir.
- En yaygın hiyerarşik kümeleme yaklaşımı aşağıdan-yukarı ya da aglomeratif kümelemedir.
- Bu yaklaşımda ağacın dallarından başlanarak gözlemler kümelenir.

Aşağıdan-Yukarıya (Bottom-Up) Yaklaşım




- Kümeleme hiyerarşisi aşağıdan yukarıya doğrudur (yapraklardan dallara doğru)

Aşağıdan-Yukarıya (Bottom-Up) Yaklaşım




- Kümeleme hiyerarşisi aşağıdan yukarıya doğrudur (yapraklardan dallara doğru)
- Birbirine yakın olan gözlemler birlikte kümelenir.

Aşağıdan-Yukarıya (Bottom-Up) Yaklaşım




- Kümeleme hiyerarşisi aşağıdan yukarıya doğrudur (yapraklardan dallara doğru)
- Birbirine yakın olan gözlemler birlikte kümelenir.

Aşağıdan-Yukarıya (Bottom-Up) Yaklaşım




- Kümeleme hiyerarşisi aşağıdan yukarıya doğrudur (yapraklardan dallara doğru)
- Birbirine yakın olan gözlemler birlikte kümelenir.
- Birbirine yakın gruplar da birlikte kümelenir.

Aşağıdan-Yukarıya (Bottom-Up) Yaklaşım




- Kümeleme hiyerarşisi aşağıdan yukarıya doğrudur (yapraklardan dallara doğru)
- Birbirine yakın olan gözlemler birlikte kümelenir.
- Birbirine yakın gruplar da birlikte kümelenir.
- En sonunda tüm gözlemleri kapsayan kümeye ulaşılır.

Aşağıdan-Yukarıya (Bottom-Up) Yaklaşım



- Dendrogram ters çevrilmiş bir ağaç gibi düşünülebilir. En altta yapraklar (gözlemler) yer almaktadır.
- Birbirine yakın gözlemler ve gruplar birleştirilerek yukarıya doğru çıkılır. Yukarıya çıktıkça küme sayısı azalmaktadır.
- Dendrogram'ın yüksekliği iki gözlemin birbirinden ne kadar farklı olduğunu gösterir.
- Grafiğin altlarında birleşen gözlemler göreceli olarak birbirine daha çok benzer.


Örnek



- Simülasyonla türetilmiş veriler, $n = 45$, iki değişken. Grup sayısı, $K = 3$, ve gözlemlerin hangi grupta yer aldığı biliniyor (ISLR, p.391).
- Grup etiketlerinin bilinmediğini varsayalım ve hiyerarşik kümele uygulayarak dendrogramını çizelim.


Dendrogram

- Birbirine yakın gözlemler daha altlarda birleşir.
- (Sol): gözlemleri temsil eden yapraklar (yeşil)
- (Orta): yatay kesikli çizgi ile kesilirse 2 grup
- (Sağ): 3 grup




Dendrogram Örnek

Hiyerarşik Kümeleme Algoritması




- Önce bir benzemezlik ölçütü (dissimilarity measure) tanımla (örneğin Öklid uzaklığı)
- Her bir gözlemin kendi grubunu oluşturduğu n küme ile başla.

Hiyerarşik Kümeleme Algoritması




- Önce bir benzemezlik ölçütü (dissimilarity measure) tanımla (örneğin Öklid uzaklığı)
- Her bir gözlemin kendi grubunu oluşturduğu n küme ile başla.
- Benzemezlik ölçütünü hesapla ve en yakın gözlemleri birleştir, örneğin (5,7). Geriye kalan küme sayısı $n - 1$

Hiyerarşik Kümeleme Algoritması




- Önce bir benzemezlik ölçütü (dissimilarity measure) tanımla (örneğin Öklid uzaklığı)
- Her bir gözlemin kendi grubunu oluşturduğu n küme ile başla.
- Benzemezlik ölçütünü hesapla ve en yakın gözlemleri birleştir, örneğin (5,7). Geriye kalan küme sayısı $n - 1$
- Sonraki en çok benzeyen kümeleri birleştir (6,1), geriye kalan = $n - 2$

Hiyerarşik Kümeleme Algoritması



- Önce bir benzemezlik ölçütü (dissimilarity measure) tanımla (örneğin Öklid uzaklığı)
- Her bir gözlemin kendi grubunu oluşturduğu n küme ile başla.
- Benzemezlik ölçütünü hesapla ve en yakın gözlemleri birleştir, örneğin (5,7). Geriye kalan küme sayısı $n - 1$
- Sonraki en çok benzeyen kümeleri birleştir (6,1), geriye kalan = $n - 2$
- Tüm gözlemler birleşip tek küme oluncaya kadar devam et.

Hiyerarşik Kümeleme Algoritması




- (5,7) grubunu (8) grubu ile birleştireceğimiz nereden biliyoruz? Benzemezlik (ya da benzerlik) ölçütünü nasıl tanımlarız?
- İki grup arasındaki benzemezlik ölçütü *bağlantı* (linkage) kavramı ile tanımlanabilir.
- Pratikte kullanılan bağlantı tipleri: tam (complete), ortalama (average), tek (single), ve ağırlık merkezi (centroid)
- Kümelemeler bağlantı tipine ve benzerlik ölçütüne göre değişebilir.

Bağlantı (Linkage) Türleri


1. **Tam Bağlantı** (complete linkage): Kümeler arasındaki en yüksek benzemezliği dikkate alır. A ve B kümesindeki gözlemler arasındaki tüm ikili benzemezlik değerleri hesaplanır ve bunların en yüksek olanı kullanılır.
2. **Tek Bağlantı** (single linkage): Kümeler arasındaki en düşük benzemezliği dikkate alır. A ve B kümesindeki gözlemler arasındaki tüm ikili benzemezlik değerleri hesaplanır ve bunların en düşük olanı kullanılır.
3. **Ortalama Bağlantı** (average linkage): Kümeler arasındaki ortalama benzemezliği dikkate alır. A ve B kümesindeki gözlemler arasındaki tüm ikili benzemezlik değerleri hesaplanır ve bunların aritmetik ortalaması kullanılır.
4. **Ağırlık Merkezi** (centroid linkage): Kümelerin ağırlık merkezleri arasındaki benzemezliği dikkate alır. Yorumlaması zor kümelemelere yol açtığı için pratikte tercih edilmez.

Bağlantı Türleri


Ortalama Bağlantı




Tam Bağlantı



Tek Bağlantı



Benzemezlik Ölçütünün Seçimi



- Benzerlik ölçüsü dendrogramın şeklini etkiler.
- Gözlemler arasında benzerliğin ölçülmesinde Öklid uzaklık ölçüsü yaygın olarak kullanılır.
- Alternatif olarak Korelasyon bazlı ölçüler de tanımlanabilir.

Yukarıdaki grafikte (Kaynak: ISLR Fig-10.13, p.398) (1) ve (3) numaralı gözlemler birbirine çok yakın (Öklid uzaklığı düşük, yani benzerliği yüksek). Ancak (1) ve (3) arasındaki korelasyon düşük, yani korelasyon-bazlı benzemezlik değeri yüksek. (1) ve (2) numaralı gözlemler ise Öklid uzaklığı yüksek (az benzer) ancak korelasyon-bazlı benzemezlik değeri düşük (çok benzer)

Özet ve Pratikte Karşılaşılan Sorunlar

- Kümeleme algoritmaları gözetimsiz öğrenmede en önemli araçlardır.
- Bu algoritmaların uygulamasında çeşitli kararların verilmesi gerekir:
 - Hem K-ortalamlar hem de hiyerarşik kümelemede değişkenlerin ölçü birimleri sonuçları etkileyebilir. Bu nedenle algoritmayı uygulamadan önce standardize etmek (ortalaması 0 standart sapması 1 olacak şekilde) gerekebilir (örnek için bkz. ISLR, s. 398-9)
 - Hiyerarşik kümelemede: hangi benzerlik ölçütü (Öklid vs. korelasyon), hangi bağlantı türü (tek, tam, ortalama), hangi noktada dendrogramın kesileceği
 - K-Ortalamlar: grup sayısının kaç olduğu.
- Pratikte farklı tercihlerin sonuçları nasıl etkilediğine bakılarak en uygun olanı tercih edilebilir.
- Sonuçların yorumlanmasında bu kararların etkili olacağı unutulmamalıdır. Sonuçlar mutlak doğru olarak yorumlanmamalıdır.